2025中国人民大学“求是学术-强国”中期报告

# 智慧教务助手建设
# 基于文档解析的RAG引擎技术研究

兰鑫、徐宇轩、马贺、张嘉琪
指导教师： 赵春晓、柯媛元
中国人民大学数学学院

## 引言

### 1. 研究背景

针对高校教务管理中“政策分散、更新快、咨询量大”的现实痛点，本项目旨在构建垂直领域的智能问答系统。教务政策散落在官网、PDF文件及公众号中，形成“信息孤岛”，师生难以精准检索；传统人工答疑难以应对海量长尾咨询。

核心目标为建设“智慧教务助手——教务小数”，利用 RAG 技术实现政策的精准解读与可信问答。

### 2. 研究链路

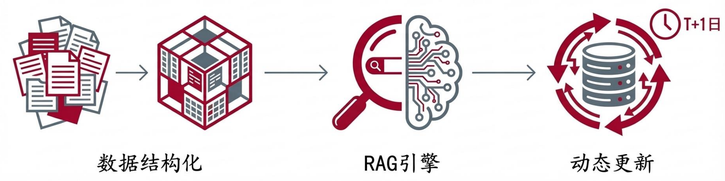


### 3. 中期研究内容

（1）多模态知识库构建：完成 42份 核心政策及 18份 学术规范的采集，清洗出 316对 高频问答数据，构建了含 2.8万条数据的专用数据集 。

（2）算法性能突破：教务领域分词准确率提升至 92.7%，实体识别 F1 值达到 89.5%，有效解决了专业术语识别难题 。

（3）幻觉抑制实效：RAG 引擎落地后，模型回答的幻觉率从 35.7% 降至 12.3%，政策依据标注率达到 100% 。

## 数据工程

### 1. 多维数据谱系

采集《本科生培养方案》《学籍管理办法》等 42份 核心政策文件及 18份 学术规范资料，覆盖课程管理、毕业要求等12个核心场景；基于访谈与邮件记录，清洗整理出 316对 有效问答数据，涵盖选课、学分转换等高频痛点 。

### 2.数学模型与算法落地

本系统引入 CRF 与 BiLSTM 模型，解决教务领域专有名词（如“跨专业选课”、“学分绩点”）的分词与实体抽取难题。引入领域专用词典（328个术语），通过优化权重参数，消除歧义。利用双向长短期记忆网络捕捉文本上下文依赖，精准提取“课程名称”、“时间节点”等关键实体。

### 3. 结构化成效

分词优化准确率达到 92.7%（较基础模型提升8.3%）。累计标注实体 1543个，F1值达到 89.5%，实现非结构化文本向结构化 JSON 数据的精准转化 。最终形成了总数据量达 2.8万条 的教务专用数据集，包含“政策文本库”、“问答配对库”和“实体标注库”三大子库 。所有数据均已转化为结构化的 JSON 格式，每条数据包含“原文内容、分词结果、实体标注、来源信息、适用场景” 5个核心字段 。

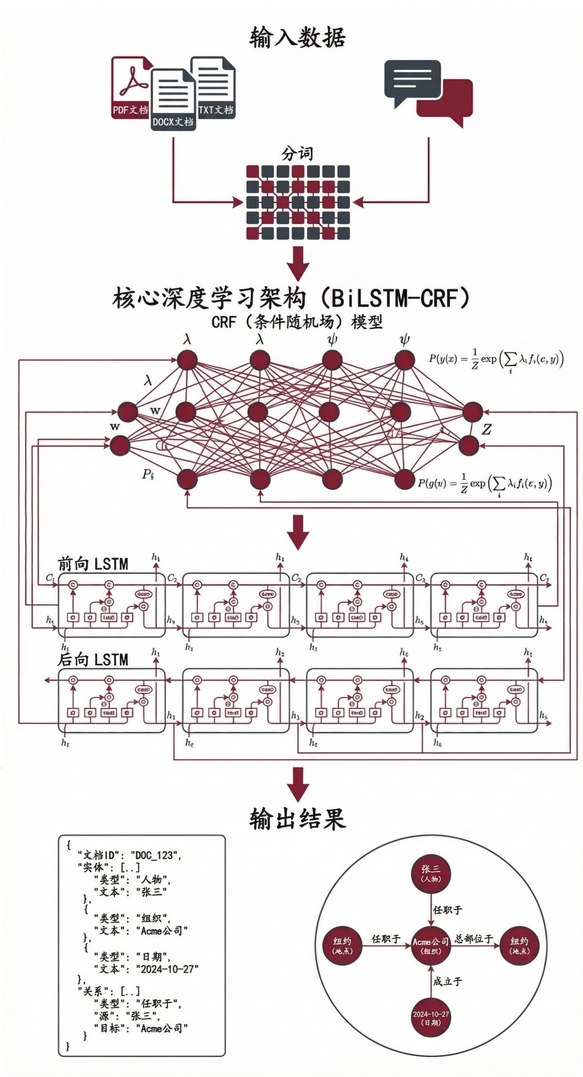


## RAG引擎 与幻觉抑制

### 1. 混合检索架构

为突破大模型“一本正经胡说八道”的瓶颈，本系统构建了RAG混合架构，通过双阶段协同保障回答的准确性：检索阶段利用 BM25 概率检索算法，从结构化知识库中精准召回与用户查询最相关的政策片段，建立关键词匹配与语义相似性的双重索引 。而在生成阶段，则将检索到的 Top-K 文档片段注入 Qwen-3-Max 大模型的上下文窗口，强制模型基于真实政策依据生成回答。

### 2. 概率检索模型

引入经典的 BM25 算法计算文档d与查询q的相关性得分，通过调节参数与平衡词频与文档长度的影响:

$$score(q,d)=\sum_{t\in q} IDF(t)\cdot\frac{f(t,d)\cdot(k_1+1)}{f(t,d)+k_1\cdot(1-b+b\cdot\frac{|d|}{avgdl})}$$

其中f(t,d) 为词频，IDF(t)为逆文档频率，avgdl为平均文档长度。

### 3. 幻觉抑制实效

于 100 条高频问题的实测验证，RAG 引擎显著提升了系统的鲁棒性：针对“重修选课时间”等典型查询，检索响应时间 < 0.3秒，文档召回率达到 90.1% 。通过微调与检索增强，模型幻觉率从微调前的 35.7% 大幅降至 12.3% 。所有生成回答的政策依据标注完整率达到 100%，真正实现“句句有出处”。

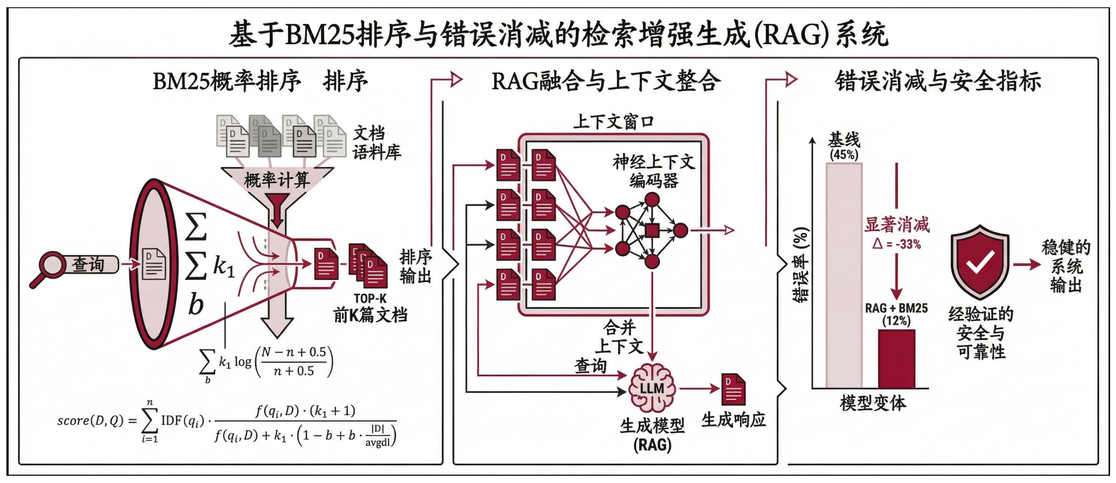


## 系统落地与交互

### 1. 沉浸式交互体验

系统前端基于 Vue 3 + Element Plus 框架开发，支持自然语言文本与语音输入。针对生成式回答，系统提供“高亮溯源”功能。用户点击回答中的引用角标，可直接跳转至政策文档原文片段，确保每一条建议都有据可查，彻底解决“黑盒”信任问题。

### 2. Human-in-the-loop 闭环迭代

为确保系统能够适应教务政策的动态变化，构建了标准化的反馈修正闭环：用户对回答进行“点赞/点踩”满意度评价，低分回答自动触发人工复核流程 。

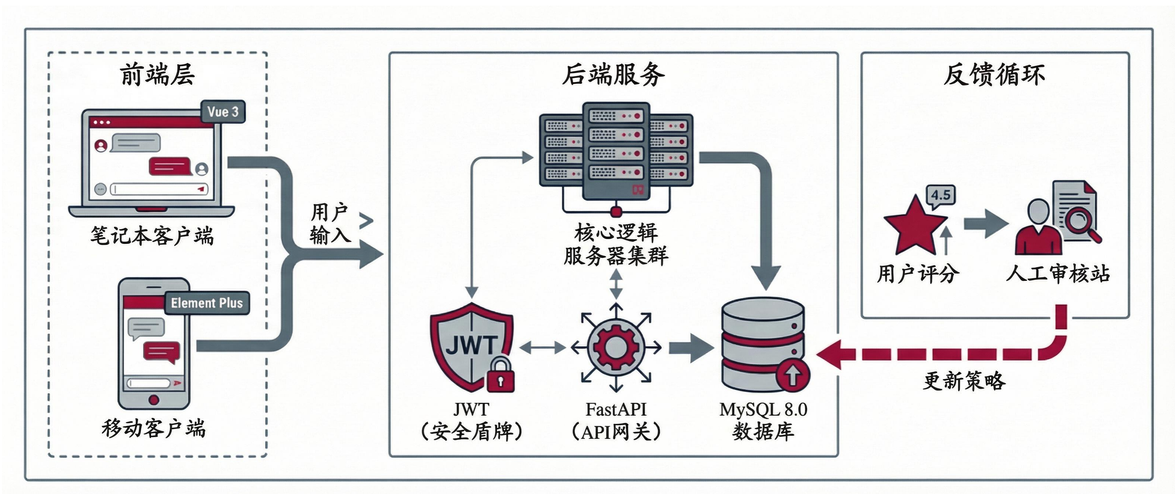


教务老师对存疑问题进行修正，并将标准问答（Q&A）录入知识库 。基于 CRUD 机制与 T+1 更新策略，新政策与修正后的知识在24小时内完成索引更新，实现系统的自我进化。

### 3. 工程架构

后端框架采用FastAPI + SQLAlchemy ORM，保障高并发下的响应速度 。采用 JWT Token 身份认证与敏感字段本地化加密存储，确保师生隐私安全 。

Tips：PPT中会展示“教务小数”的实际对话界面，让各位直观看到产品雏形。

## 后续方向

### 1. 感知层：多模态智能实装

打破纯文本交互限制，构建“听得见、看懂图”的教务助手。

(1) 全场景输入：开发支持 文本+图片+语音 的多模态最小可用版本（MVP）。

(2) 深度视觉解析：引入 OCR + 版式理解 技术，重点攻克“跨页表格”、“无边界表格”及“复杂公式”的识别难题，支持用户直接上传课表截图或通知照片进行解析 。

(3) 性能目标：实现文档段落定位F1>0.9，表格字段抽取准确率>95%。

### 2. 决策层：多智能体协作框架

从单体 RAG 向 “Agent 编排” 架构升级，实现复杂任务的自动化处理。

(1) 路由 Agent：作为“大脑”，智能判断问题类型，将其分发至本地知识库、通用大模型或复杂流程处理模块 。

(2) 文档解析 Agent：专门负责政策文件的批量化结构处理与版式还原 。

(3) 合规 Agent：负责敏感字段检测与价值观审校，确保输出内容的安全性与合规性 。

(4) 闭环机制：基于 DAG（有向无环图）与状态机保证流程可观测、可回退。。

### 3. 触达层：全平台生态与知识图谱

(1) 双端对齐：完成 Web 端 + 移动端小程序 的全功能适配，支持弱网环境优化与任务队列可视化，随时随地响应师生需求 。

(2) 图谱融合：构建 “教务知识图谱 + RAG + Agent” 一体化平台，不仅回答问题，更能基于用户画像提供个性化的学业规划建议与教师科研信息推荐 。

(3) 基于用户画像与图谱推理，系统将提供个性化学业规划与教师科研信息推荐实现从“人找信息”到“信息找人”的转变 。